

PRÁCTICA 3

Explicación de la fuente de datos pública utilizada

Para realizar esta práctica, he utilizado la API de la NASA. Concretamente, el apartado "Mars Rover Photos", que recopila las imágenes tomadas por los robots Curiosity, Opportunity y Spirit de la NASA en Marte.

He decidido utilizar esta fuente de datos porque me gustan los temas relacionados con el espacio y porque me parecía interesante poder obtener tantas imágenes del espacio, debido a que luego se pueden usar para Machine Learning, por ejemplo. También he elegido esta API porque la documentación es de calidad, lo que me ha facilitado entender cómo utilizarla.

Descripción del flujo de datos

Antes de comenzar a explicar los pasos seguidos, quiero mencionar que he hecho muchas pruebas probando distintos procesadores y configurándolos de distinta manera para conseguir que funcionase. Pero lo voy a explicar como si me hubiese funcionado todo correctamente a la primera porque si no se va a hacer muy largo y lioso.

Pasos seguidos:

1. He creado un grupo de procesadores y le he llamado "Practica3".
2. He añadido el procesador "InvokeHTTP" y le he cambiado el nombre a uno más descriptivo. Lo he configurado para que llame a la API cada hora y le he añadido la URL para obtener un JSON, en el cual se encuentran los enlaces a las imágenes de Marte tomadas por la NASA, entre otra información más.
3. He añadido el procesador "ConvertRecord" y le he cambiado el nombre a uno más descriptivo. En "Record Reader" le he añadido la propiedad "JsonTreeReader" y en "Record Writer" le he añadido la propiedad "JsonRecordSetWriter" (la cual he configurado para que saque el JSON ya formateado, utilizando la propiedad "Pretty Print JSON" en "true"). Esto lo he hecho porque el JSON proveniente de la NASA viene sin formatear, es decir, que todo está en una sola línea, por lo que, si no lo formatease, luego el procesador "SplitText" no funcionaría correctamente.
4. He añadido el procesador "SplitText" y le he cambiado el nombre a uno más descriptivo. He configurado la propiedad "Line Split Count" en "1" para que separe cada línea del JSON.

- 5.** He añadido el procesador "RouteOnContent" y le he cambiado el nombre a uno más descriptivo. Antes de explicar cómo lo he configurado, quiero decir que estuve probando con otros procesadores que sí habíamos dado en clase, pero ninguno me funcionaba correctamente, así que investigué y encontré este.
- 6.** Ahora voy explicar cómo he configurado el procesador del paso anterior. La propiedad "Match Requirement" la he configurado en "content must contain match", la propiedad "Content Buffer Size" en "10MB" y, además, le he añadido una propiedad llamada "hasImg" con valor "http". Esta última lo que hace es comprobar si la línea contiene un enlace a una imagen; si la tiene le deja continuar al siguiente procesador y, si no, no.
- 7.** He añadido el procesador "ReplaceText" y le he cambiado el nombre a uno más descriptivo. La propiedad "Maximum Buffer Size" la he configurado en "10MB" y a la propiedad "Search Value" le he añadido el valor `".*"img_src"?: ?"(http[^\"]*)".*"` para que elimine todo lo que no sea parte del enlace.
- 8.** He añadido el procesador "UpdateAttribute" y le he cambiado el nombre a uno más descriptivo. He añadido la propiedad "filename" y le he añadido el valor `"imagenNasa-#{nextInt()}.txt"` para que le asigne un nombre único a cada imagen y para que estén enumeradas.
- 9.** El último procesador que he añadido ha sido "PutFile" y le he cambiado el nombre a uno más descriptivo. Lo he configurado para que su directorio de salida sea la carpeta `"/tmp/out"`.
- 10.** He relacionado todos los procesadores y he configurado las relaciones.
- 11.** Por último, he añadido un Label con mi nombre.

Resumen:

- 1.** Obtengo un JSON de la API de la NASA, que incluye enlaces a imágenes de Marte.
- 2.** Lo transformo para descartar toda la información que no sea un enlace.
- 3.** Separo cada enlace en un archivo .txt y lo almaceno en el directorio `"/tmp/out"`.